

医学影像分析（实验三）

题目：实验三：实现一个基于深度卷积网络的医学图像分割算法

学生姓名：	王天也
学 号：	21S010051
所在学院：	经济与管理学院
专业名称：	管理科学与工程

2022 年 5 月

目 录

1	实验三，实现一个基于深度卷积网络的医学图像分割算法	1
1.1	实验目的	1
1.2	实验原理	1
1.3	实验步骤	4

1 实验三，实现一个基于深度卷积网络的医学图像分割算法

1.1 实验目的

熟悉 FCN、U-Net、V-net 等基于深度学习的医学图像分割网络

1.2 实验原理

1. 语义分割

语义分割，也称为基于像素的分类，是一项重要的任务，我们将图像的每个像素分类为属于特定类别。

语义分割的目标与遥感中传统的图像分类相同，通常是通过应用随机森林和最大似然分类器等传统机器学习技术进行的。与图像分类一样，语义分割也有两个输入。

包含多个波段的光栅图像，

包含每个像素标签的标签图像。

语义分割算法有很多，如 U-net、Mask R-CNN、Feature Pyramid Network (FPN) 等。在本报告中，我们将主要解释 U-net，它是最被认可的图像分割算法之一并且许多想法在其他算法中共享。

2. U-Net 架构

U-net 最初是发明并首先用于生物医学图像分割。它的架构可以广泛地被认为是一个编码器网络，然后是一个解码器网络。与深度网络的最终结果是唯一重要的分类不同，语义分割不仅需要在像素级别进行区分，而且还需要一种将在编码器不同阶段学习到的判别特征投射到像素空间的机制。

编码器是架构图中的前半部分。它通常是一个预训练的分类网络，如 VGG/ResNet，在其中应用卷积块，然后进行最大池化采样，以将输入图像编码为多个不同级别的特征表示。

解码器是架构的后半部分。目标是将编码器学习的判别特征（较低分辨率）语义投影到像素空间（较高分辨率）以获得密集分类。解码器包括上采样和连接，然后是常规卷积操作。

U-net 架构如上图所示。它由收缩路径和扩张路径组成。

收缩路径

连续进行两次 3×3 Conv 和 2×2 最大池化。这可以帮助提取更高级的特征，但也可以减小特征图的大小。

扩展路径

连续进行 2×2 Up-conv 和两次 3×3 Conv 以恢复分割图的大小。然而，上述过程虽




图 1.1 U-net 架构。蓝色框表示多通道特征图，而框表示复制的特征图。不同颜色的箭头代表不同的操作

然增加了“what”，但减少了“where”。这意味着，我们可以获得高级功能，但也会丢失本地化信息。因此，在每个 up-conv 之后，我们还连接了具有相同级别的特征图（灰色箭头）。这有助于给出从收缩路径到扩展路径的定位信息。最后， 1×1 conv 将特征图大小从 64 映射到 2，因为输出特征图只有 2 个类，细胞和膜。

重叠平铺策略

由于使用了未填充的卷积，因此输出大小小于输入大小。不是在网络之前缩小尺寸，在网络之后进行上采样，而是使用重叠平铺策略。因此，整个图像如上图所示逐部分预测。使用蓝色区域预测图像中的黄色区域。在图像边界，通过镜像外推图像。




图 1.2 重叠平铺策略

用于数据增强的弹性变形

由于训练集只能由专家注释，因此训练集很小。为了增加训练集的大小，数据增强是通过随机变形输入图像和输出分割图来完成的。

接触物体的分离

由于触摸对象彼此紧密放置，因此它们很容易被网络合并，为了将它们分开，将权重图应用于网络的输出。

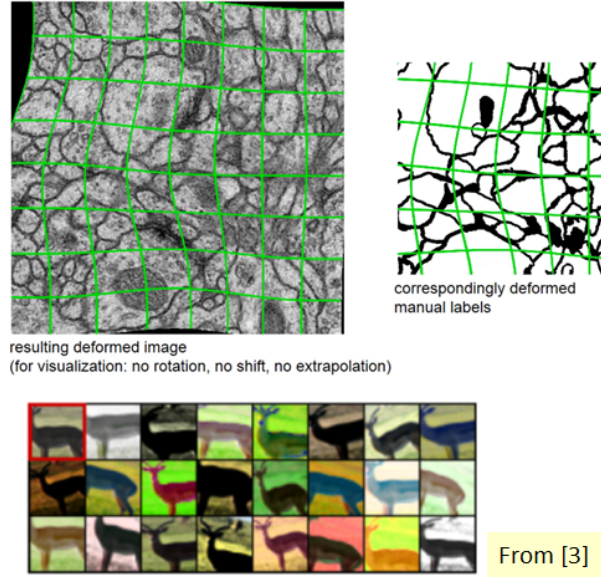


图 1.3 弹性变形




图 1.4 分割图（左）和权重图（右）

$$\omega(x) = \omega_c(x) + \omega_0 * \exp\left(-\frac{(d_1(x) + d_2(x))^2}{2\sigma^2}\right)$$

如上计算权重图， $d_1(x)$ 是到位置 x 最近的单元格边界的距离， $d_2(x)$ 是到第二个最近的单元格边界的距离。因此，在边界处，重量比图中高得多。

$$p_k(x) = \exp(a_k(x)) / \left(\sum_{k'=1}^K \exp(a_{k'}(x))\right)$$

$$E = \sum_{x \in \Omega} \omega(x) \log(p_{l(x)}(x))$$

因此，交叉熵函数在每个位置都受到权重图的惩罚。它有助于迫使网络学习接触细胞之间的小分离边界。

1.3 实验步骤

1. 数据

原始数据集来自 http://brainiac2.mit.edu/isbi_challenge/，我已经下载了它并完成了预处理。

保存在在文件夹 Data/membrane 中




图 1.5 原始图像

2. 数据增强

训练数据包含 30 512*512 张图像，远远不足以为深度学习神经网络提供能量。我在 `keras.preprocessing.image` 中使用一个名为 `ImageDataGenerator` 的模块来做数据增强。

在深度学习任务中，需要大量的数据来训练 DNN 模型，当数据集不够大时，应该应用数据增强。

`keras.preprocessing.image.ImageDataGenerator` 是一个数据生成器，它可以为 DNN 提供如下数据：(data, label)，它也可以同时进行数据增强。

对于我们来说，使用 `keras.preprocessing.image.ImageDataGenerator` 通过实现图像旋转，移位，重新缩放等来进行数据增强非常方便

数据增强结果在 Data/membrane/train/aug 文件中

3. 模型

这个深度神经网络是用 Keras 函数式 API 实现的，这使得尝试不同的有趣架构变得非常容易。

网络的输出是一个 512 * 512，它表示应该学习的掩码。乙状结肠激活功能确保遮罩像素在 [0, 1] 范围内。



图 1.6 原始标签图像

4. 训练

该模型训练了 5 个迭代。

5 个迭代后，计算精度约为 0.97。

训练的损失函数基本上只是一个二元交叉熵。

5. 结果

运行 model.py 文件分割结果可以在 Data/membrane/test 中查看

这个实验的处理文件的代码都在“实验三的文件中”